

UNIVERSIDADE FEDERAL FLUMINENSE
ESCOLA DE ENGENHARIA
GRADUAÇÃO EM ENGENHARIA MECÂNICA

ARMANDO OLIVEIRA SODRÉ

APLICAÇÃO DE ALGORITMOS DE INTELIGÊNCIA
ARTIFICIAL PARA DETERMINAÇÃO DE CORRELAÇÕES
EMPÍRICAS EM MODELOS DE TRANSFERÊNCIA DE
CALOR E MASSA

NITERÓI, RJ

2022

ARMANDO OLIVEIRA SODRÉ

**APLICAÇÃO DE ALGORITMOS DE INTELIGÊNCIA
ARTIFICIAL PARA DETERMINAÇÃO DE CORRELAÇÕES
EMPÍRICAS EM MODELOS DE TRANSFERÊNCIA DE
CALOR E MASSA**

Trabalho de Conclusão de Curso
apresentado ao Curso de Engenharia Mecânica da
Universidade Federal Fluminense, como requisito
parcial para obtenção do grau de Engenheiro
Mecânico.

Orientador:
Prof. Cesar Cunha Pacheco

Niterói, RJ
2022.

Ficha Catalográfica elaborada pela Biblioteca da Escola de Engenharia e Instituto de Computação da UFF

Após finalizar o trabalho, gerar a ficha catalográfica a partir do link a seguir:

<http://www.bibliotecas.uff.br/bee/ficha-catalografica>

Necessita-se da definição de termos de busca como assunto, conforme instruções apresentadas no link previamente descrito.

Para inserir a ficha catalográfica neste trecho do documento, recomenda-se a utilização de caixa de texto (aba “Inserir” → “Caixa de texto”), pois assim pode-se ajustar a posição mais facilmente.

ARMANDO OLIVEIRA SODRÉ

**APLICAÇÃO DE ALGORITMOS DE INTELIGÊNCIA
ARTIFICIAL PARA DETERMINAÇÃO DE
CORRELAÇÕES EMPÍRICAS EM MODELOS DE
TRANSFERÊNCIA DE CALOR E MASSA**

Trabalho de Conclusão de Curso
apresentado ao Curso de Engenharia
Mecânica da Universidade Federal
Fluminense, como requisito parcial para
obtenção do grau de Engenheiro Mecânico.


Grau: 9.0

Aprovado em 22/12/2022.


BANCA EXAMINADORA



Prof. DSc. Cesar Cunha Pacheco – UFF
Orientador



Prof. DSc. Leandro Alcoforado Sphaier – UFF



DSc. Vinicius Ribeiro Machado da Silva – TechnipFMC

Niterói, RJ

2022

AGRADECIMENTOS

A trajetória de graduação em engenharia mecânica na UFF foi desafiadora, em certos momentos frustrante, e principalmente engrandecedora. Se essa trajetória está chegando ao fim e estou saindo, espero que, um indivíduo melhor que o que se matriculou em 2016, é graças as pessoas que estiverem no meu caminho até aqui. Gostaria de agradecer à todos que impactaram de alguma forma nesse caminho tortuoso.

A meus familiares, em especial meu pai, minha mãe, meu irmão e minha madrinha, que sempre me apoiaram e estiverem comigo, para comemorar as conquistas e dar suporte nos momentos difíceis. Minha madrinha não só sempre esteve lá comigo, como também me recebeu com os braços abertos em sua casa quando fui para Niterói começar o curso, e serei eternamente grato por sua recepção e todo seu carinho.

A todos os meus amigos, os que já conhecia, e aqueles que tive o prazer de conhecer por causa da UFF. Nos momentos de felicidade e no fundo do poço, existia uma coisa em comum, eles estavam lá comigo. E em uma segunda etapa da minha vida, começando a vida profissional, um deles também me recebeu de braços abertos em sua casa, muito obrigado Luis Guilherme. E um agradecimento especial aos grupos ConSultorio, PDP, e a Panelinha.

Também é necessário agradecer ao projeto de extensão Faraday e-racing. Um projeto que definiu boa parte da minha vida e dedicação na universidade. 4 anos de muitas experiências, onde vivi de tudo e um lugar que deixou uma marca enorme em mim que carregarei para a vida.

Por fim, devo agradecer ao grupo de Methods & Software da TechnipFMC, grupo onde prestei meu estágio e me instigou a seguir no caminho de programação e ciência de dados, que hoje moldaram esse trabalho.

Muito Obrigado!

Epígrafe

“It’s nice to be importante but it’s more importante to be nice”

John Templeton

RESUMO

O trabalho discorre sobre a metodologia e resultados do uso de ferramentas de aprendizado de máquina e inteligência artificial para problemas de transferência de calor.

No campo de estudo de transferência de calor é comum a elaboração de correlações empíricas para prever comportamentos desses sistemas. O desenvolvimento dessas correlações, porém, demanda muita energia e tempo para experimentos, propostas e validação.

Novas ferramentas de inteligência artificial e aprendizado de máquina têm se tornado cada vez mais robustas e acessíveis, tendo aplicações nos mais diversos campos de pesquisa. O trabalho propõe um modelo baseado em programação genética que seja capaz de propor novas correlações para o caso de estudo. A eficácia do modelo será usada como prova de conceito para avaliar o uso de aprendizado de máquina para problemas no tema, podendo escalar para casos mais complexos.

Para se avaliar a capacidade dessa ferramenta, o modelo será testado em um sistema de convecção de calor forçada ao redor de um cilindro. Existem diversos estudos abordando esse tipo de escoamento, e correlações empíricas já consolidadas, sendo um bom teste comparativo para o modelo desenvolvido.

Palavras-chave: Aprendizado de máquina, Transferência de calor, Convecção forçada.

ABSTRACT

The paper discusses the methodology and results of using machine learning and artificial intelligence tools for heat transfer problems.

In the field of heat transfer, it is common to develop empirical correlations to predict the systems behavior. The development of these correlations, however, demands a lot of energy and time for experiments, proposals, and validation.

New artificial intelligence and machine learning tools have become increasingly robust and accessible, with applications in various fields of research. This paper proposes a model based on genetic programming that is able to propose new correlations for the one system. The effectiveness of the model will be used as a proof of concept to evaluate the use of machine learning for problems in the subject, and if it can be scaled to more complex cases.

To evaluate the capability of this tool, the model will be tested on a system of forced heat convection around a cylinder. There are several studies addressing this type of flow, and empirical correlations already consolidated, being a good comparative test for the model to be developed.

Keywords: Machine learning, Heat transfer, Forced convection

LISTA DE ILUSTRAÇÕES

Figura 1.1 Abordagem tradicional Fonte: Traduzido de Géron (2019)	3
Figura 1.2 Abordagem do aprendizado de máquina Fonte: Traduzido de Géron (2019)	3
Figura 1.3 - Exemplos de overfit, underfit, e o modelo ideal Fonte: BADILLO (2020)	6
Figura 2.1- Resumo das correlações para convecção forçada sobre corpos 1/3 Fonte: OZISIK (1985)	9
Figura 2.2Resumo das correlações para convecção forçada sobre corpos 2/3 Fonte: OZISIK (1985)	10
Figura 2.3 - Resumo das correlações para convecção forçada sobre corpos 3/3 Fonte: OZISIK (1985)	10
Figura 3.1 Regimes de escoamento através de um cilindro Fonte: Lienhard (1966).	14
Figura 3.2 Medidas de Geidt's de transferência de calor local em um escoamento de ar ao redor de cilindro. Fonte: Giedt's (1949).	15
Figura 3.3 - Comparação da correlação de Churchill e Bernstein com dados experimentais de outros trabalhos Fonte: Adaptado de LIENHARD (2005).....	17
Figura 4.1 - Diagrama ilustrando a lógica do algoritmo genético. Fonte: https://icarogostino.github.io/post/sbo/	19
Figura 4.2 Esquema ilustrando um algoritmo genético Fonte: Traduzido de BRUNTON (2022)	20
Figura 4.3 Função representada como árvore de função.....	21
Figura 4.4 Operações usadas nas árvores de funções, e as taxas para cada operação Fonte: Traduzido de BRUNTON (2022).....	22
Figura 4.5 – Distribuição dos dados usados no desenvolvimento do modelo.....	23
Figura 4.6 – Distribuição dos dados utilizados no desenvolvimento do modelo para Re > 50000	24
Figura 4.7 – Exemplos de valores de comportamento de R^2 Fonte: Glen (2022)	27
Figura 5.1- Evolução da função de custo do modelo 1	29
Figura 5.2- Comparação dos dados experimentais, previstos pelo modelo1, e calculados da equação de Churchill-Bernstein.....	30
Figura 5.3 - Valores dos erros do modelo 1 e da equação de Churchill-Bernstein	31
Figura 5.4- Evolução da função de custo do modelo 2	32

Figura 5.5 - Comparação dos dados experimentais, previstos pelo modelo2, e calculados da equação de Churchill-Bernstein	32
Figura 5.6 - Valores dos erros do modelo 2 e da equação de Churchill-Bernstein ...	33
Figura 5.7-Evolução da função de custo do modelo 3.....	34
Figura 5.8- Comparação dos dados experimentais, previstos pelo modelo3, e calculados da equação de Churchill-Bernstein	35
Figura 5.9 - Valores dos erros do modelo 3 e da equação de Churchill-Bernstein ...	36
Figura 5.10- Árvore função do modelo 3	37
Figura 5.11- Evolução da função de custo do modelo 4.....	38
Figura 5.12- Comparação dos dados experimentais, previstos pelo modelo4, e calculados da equação de Churchill-Bernstein	38
Figura 5.13 - Valores dos erros do modelo 4 e da equação de Churchill-Bernstein .	39
Figura 5.14- Árvore função do modelo 4	40

LISTA DE TABELAS

Tabela 5.1- Parâmetros e resultados do modelo 1	29
Tabela 5.2- Parâmetros e resultados do modelo 2	31
Tabela 5.3- Parâmetros e resultados do modelo 3	34
Tabela 5.4- Parâmetros e resultados do modelo 4	37

LISTA DE SÍMBOLOS

Re	número de Reynolds
Pr	número de Prandtl
Nu	número de Nusselt
MAE	Mean Absolute Error
MSE	Mean Squared error
m	Número de dados de treino
x^i	Vetor característico de um dado
X	Matriz característica de todos os dados
h	Valor predito pelo modelo
y	Valor alvo
R^2	Coeficiente de determinação
SQ_{res}	Soma do quadrado dos resíduos
SQ_{tot}	Soma total dos quadrados
y_i	Valor observado
$\hat{y}_i$	Valor previsto para y_i
$\bar{y}$	Média das observações

SUMÁRIO

1	Introdução	1
1.1	Transferência de calor convectiva.....	1
1.2	Motivação:.....	1
1.3	Aprendizado de máquina.....	2
1.3.1	Função de custo	4
1.3.2	Overfitt e underfitt	5
1.4	Objetivos	6
1.5	Organização do texto.....	6
2	Revisão da literatura	9
2.1	Convecção de calor	9
2.2	Aprendizado de máquina.....	11
3	Convecção de calor forçada ao redor do cilindro	13
4	Aprendizado de máquina	19
4.1	Algoritmo Genético.....	19
4.2	Programação Genética.....	20
4.3	base de dados.....	22
4.4	Desenvolvimento do modelo.....	24
4.5	Coeficiente de determinação (R^2).....	25
5	Resultados.....	29
5.1	Modelo 1	29
5.2	Modelo 2	31
5.3	Modelo 3	34
5.4	Modelo 4	37
6	Conclusões.....	41
6.1	Sugestões para trabalhos	41
7	Referências bibliográficas	43

Apêndice A. Dados 44

A.1 Dados experimentais 44

1 INTRODUÇÃO

1.1 TRANSFERÊNCIA DE CALOR CONVECTIVA

O conceito de energia é usado em termodinâmica para definir o estado de um sistema. Sabe-se que energia não é criada ou destruída, mas muda de forma. A termodinâmica lida com a relação do calor com outras energias, mas a transferência de calor se concentra no estudo da taxa da transferência de calor ocorrendo em um sistema. Sabe-se que o calor flui de uma região de maior temperatura, para uma de menor temperatura, logo, se há um gradiente de temperatura, há transferência de calor. A energia transportada pelo fluxo de calor não pode ser medida diretamente, porém ela está relacionada diretamente à temperatura, que é uma grandeza que pode ser mensurada.

Determinar o mapa de temperatura e o fluxo de calor de um sistema é essencial para o desenvolvimento de diversas áreas da engenharia. Para o dimensionamento de trocadores de calor (condensadores, e radiadores, por exemplo); na indústria aeroespacial, visando atender os requerimentos dimensionais e de segurança; dimensionamento de sistemas de aquecimento e de ar-condicionado.

O calor pode fluir pelo sistema de três diferentes formas: condução, convecção e radiação. O foco do trabalho será em caso convectivo.

O estudo de casos de convecção é, muitas vezes, complexo. A movimentação do fluido afeta na pressão e arrasto, e por consequência na transferência de calor. A distribuição dos dados de velocidade do fluido no sistema se torna, então, necessária para o desenvolvimento destes casos. Porém, muitas vezes as propriedades do fluido variam com a temperatura, e não é possível mapear a velocidade sem saber a temperatura, e vice-versa. Essa interdependência dificulta as soluções para esse tipo de sistema, e por isso a elaboração de relações de generalização e correlação para a transferência de calor convectiva de maneira empírica é o foco de diversos estudos em transferência de calor.

1.2 MOTIVAÇÃO:

Atualmente o cálculo do coeficiente de transferência de calor é feito de forma analítica por equações já propostas em literatura, que serão abordadas ao longo do trabalho. Essas

soluções, no entanto, podem apresentar erros relevantes associados a determinadas condições de contorno, como à um intervalo de velocidade do fluido ou à um perfil de velocidade específico, tornando uma solução menos confiável. Além disso, a elaboração dessas correlações demanda de muita energia para serem propostas, testadas e validadas, vide o trabalho desenvolvido por Churchill e Bernstein(1977) que será abordado.

Uma alternativa consolidada é o uso de simulações fluidodinâmicas computacionais, ou ***Computational Fluid Dynamics (CFD)***, porém esse tipo de simulação também apresenta complicadores. Para modelos complexos as simulações CFD apresentam alto custo computacional e de tempo para serem processados, além de ser necessário o conhecimento no uso do software sendo utilizado.

Portanto, o trabalho tem como motivação a elaboração de um modelo computacional de aprendizado de máquina, que processe os dados mais rapidamente, e ser mais preciso que as expressões analíticas já propostas. Esse caso será tomado como uma prova de conceito para o uso desse tipo de tecnologia do campo da transferência de calor

1.3 APRENDIZADO DE MÁQUINA

Um dos primeiros usos do termo machine learning foi dado na pesquisa de Samuel (1967), em um trabalho baseado em um jogo de damas. Machine learning, ou aprendizado de máquina em português, é um dos ramos dentro do contexto de inteligência artificial. Esses modelos são alimentados com uma base de dados, e por meios destes dados, treinam (ou aprendem) a fazer previsões ou classificações, sendo capaz de generalizar para novos casos fora do domínio daqueles que foram usados para o treinamento.

Em seu livro, Géron (2019) traz uma definição de Tom Mitchell para aprendizado de máquina, orientada à engenharia: “Alega-se que um programa de computador aprende pela experiência E em relação a algum tipo de tarefa T e em alguma medida de desempenho P se o seu desempenho em T, conforme medido por P, melhora com a experiência E.”.

Dessa forma, enquanto para uma abordagem de programação tradicional à um problema seria necessário escrever explicitamente as regras do problema, como ilustrado na Figura 1.1, o aprendizado de máquina permite que o programa aprenda as regras por conta própria, a partir dos dados fornecidos ao mesmo (Figura 1.2). Os pontos importantes então no segundo caso são, além do conhecimento do problema, a qualidade dos dados fornecidos, e ter conhecimento das ferramentas de aprendizado de máquina melhor se adequam ao caso.




Figura 1.1 Abordagem tradicional Fonte: Traduzido de Géron (2019)




Figura 1.2 Abordagem do aprendizado de máquina Fonte: Traduzido de Géron (2019)

Apesar do modelo de Samuel ter sido desenvolvido ainda na década de 50, algoritmos de aprendizado de máquina não começaram a ser amplamente utilizados de maneira prática até a virada do século XXI. Na virada do século o poder computacional se tornou mais acessível, viabilizando o treinamento de algoritmos de inteligência artificial com maior quantidade de dados, em uma velocidade de processamento maior. Novas pesquisas no campo recuperaram

força e financiamento, e o aprendizado de máquina começou a ser utilizado em aplicações práticas por empresas e pesquisadores.

Alguns exemplos comuns de aplicações de inteligência artificial em nosso dia a dia são: sistemas de combate de fraudes em pagamento; tradução de textos instantâneos; e recomendações de conteúdo em redes sociais e e-commerce.

Dentre as ferramentas de aprendizado de máquina, a escolha do tipo do algoritmo que melhor se adequa aos objetivos é importante, visto que o algoritmo dita como o modelo se comporta, aprende, e como é estruturado após o treinamento. Dentre os algoritmos mais populares estão o de árvores de decisão, florestas aleatórias, XGBoost, redes neurais, dentre outros, e cada um com suas particularidades.

A regressão simbólica será abordada nesse estudo. Este algoritmo tem a vantagem de ter como resultado uma expressão analítica única para os dados analisados, ou seja, o modelo irá encontrar uma correlação a partir dos dados. No âmbito científico esse tipo de resultado pode ser muito valioso, tornando mais fácil a análise das regras criadas pelo algoritmo, comparação com correlações anteriores, e facilidade para compartilhar o resultado entre pesquisadores.

1.3.1 FUNÇÃO DE CUSTO

A função custo é o guia para o aprendizado do modelo. A função custo avalia quão bem um algoritmo está reagindo a determinados dados, e com essa informação, se ajusta para diminuir o erro. Se as previsões estiverem muito distantes dos resultados reais, a função custo terá resultados altos, e quanto melhor o algoritmo se ajustar aos dados, menor será seu valor. Ao longo de um processo iterativo o modelo modifica seus parâmetros com o objetivo de reduzir os valores da função custo escolhida.

Dois exemplos mais comuns de funções de custo são, o erro médio absoluto (MAE):

$$MAE(X, h) = \frac{1}{m} \sum_{i=1}^m |h(x^i) - y^i| \quad (1.1)$$

Onde:

m : número de dados de treino

x^i : vetor característico de um dado

X : matriz característica de todos os dados

h : Valor predito pelo modelo

y : valor alvo

E o erro quadrático médio (MSE):

$$MSE(X, h) = \frac{1}{m} \sum_{i=1}^m (h(x^i) - y^i)^2 \quad (1.2)$$

Além das duas funções descritas, existem outras funções de erro, e cada uma se adequa melhor à problemas e dados diferentes, como a função de Hubber ou a de Poisson.

1.3.2 OVERFIT E UNDERFIT

O objetivo do aprendizado de máquina é desenvolver um modelo que seja capaz de aprender com os dados recebidos e que, a partir deles, seja capaz de extrapolar sua metodologia para novos casos. Uma forma de avaliar como está a performance do modelo nesse quesito são os fenômenos de underfit e overfit. Dizemos que o modelo está em underfit quando este não é treinado o suficiente para uma boa generalização dos dados. Por outro lado, o modelo está em overfit quando o erro é baixo para o treinamento, porém não consegue generalizar essa performance para novos dados. A figura 1.3 ilustra os fenômenos para um caso de regressão.




Figura 1.3 - Exemplos de overfit, underfit, e o modelo ideal Fonte: BADILLO (2020)

1.4 OBJETIVOS

Este projeto de pesquisa tem como objetivo principal o desenvolvimento de um modelo de aprendizado de máquina capaz de prever o coeficiente de transferência de calor de convecção forçada através de um cilindro. Os seguintes objetivos específicos podem ser listados:

- Avaliar diferentes modelos de aprendizado de máquina para resolução do problema
- Alcançar um modelo capaz de gerar resultados satisfatórios
- Analisar os padrões e correlações dos dados percebidos pelo modelo
- Avaliar o custo e precisão dos resultados gerados
- Encontrar uma nova correlação para o problema

1.5 ORGANIZAÇÃO DO TEXTO

Este documento foi organizado em capítulos abordando os seguintes tópicos:

- Capítulo 1: A presente introdução
- Capítulo **Error! Reference source not found.**: Expõe a revisão de literatura realizada para o desenvolvimento do trabalho
- Capítulo 3: Elabora sobre o problema de convecção de calor
- Capítulo 5: Aprofunda o assunto de aprendizado de máquina

- Capítulo 5: Apresenta os resultados
- Capítulo 6: Discorre sobre a conclusão e trabalhos futuros
- Capítulo 7: Revisão bibliográfica usada como referência ao longo do trabalho

2 REVISÃO DA LITERATURA

Nesse capítulo será abordado os estudos e pesquisas realizados durante a elaboração do trabalho. Em um primeiro momento voltado para o tema de transferência de calor, e posteriormente para o estudo de aprendizado de máquina

2.1 CONVECÇÃO DE CALOR

A elaboração de correlações que discretizem o comportamento do fluxo de calor de um sistema, é um grande foco nessa área. OZISIK (1985) traz em seu livro um histórico de diversas correlações desenvolvidas para diferentes aplicações no campo de transferência de calor. Como nas figuras 2.1, 2.2 e 2.3 que apresentam um resumo das correlações para convecção forçada sobre corpos.

Table 8-6 Summary of correlations for forced convection over bodies*

Equation number	Correlation	Flow regime	Remarks
(8-19)	$c_x = \frac{0.664}{Re_x^{1/2}}$ (local)	Laminar	Flow over a flat plate for $Re_x \leq 5 \times 10^5$
(8-21)	$c_m = \frac{1.328}{Re_L^{1/2}}$ (average)	Laminar	Flow over a flat plate for $Re_L \leq 5 \times 10^5$
(8-22)	$\frac{\delta(x)}{x} = \frac{4.96}{Re_x^{1/2}}$	Laminar	Flow over a flat plate for $Re_x \leq 5 \times 10^5$
(8-24)	$c_x = 0.0592 Re_x^{-0.2}$ (local)	Turbulent	Flow over a flat plate for $5 \times 10^5 < Re_x < 10^7$
(8-25)	$c_x = 0.370(\log Re_x)^{-2.584}$ (local)	Turbulent	Flow over a flat plate for $10^7 < Re_x < 10^9$
(8-25b)	$c_m = 0.074 Re_L^{-0.2} - \frac{B}{Re_L}$ (average)	Laminar and turbulent	Flow over a flat plate for $Re_x < Re_L < 10^7$
(8-26b)	$\frac{\delta(x)}{x} = 0.381 Re_x^{-1/5} - 10,256 Re_x^{-1}$	Laminar and turbulent	Flow over a flat plate for $5 \times 10^5 < Re_x < 10^7$
(8-45)	$Nu_x = 0.564 Pe_x^{1/2}$ (local)	Laminar	Flow over a flat plate, constant wall temperatures, $Pr \ll 1$
(8-67)	$Nu_x = 0.332 Pr^{1/3} Re_x^{1/2}$ (local)	Laminar	Flow over a flat plate, constant wall temperature,
(8-73a)	$St_x Pr^{2/3} = 0.0296 Re_x^{-0.2}$ (local)	Turbulent	Flow over a flat plate for $5 \times 10^5 < Re_x < 10^7$ $Re_x \leq 5 \times 10^5$; $0.6 < Pr < 10$
(8-68)	$Nu_x = 0.339 Pr^{1/3} Re_x^{1/2}$ (local)	Laminar	Flow over a flat plate, constant wall temperature, $Re_x \leq 5 \times 10^5$, $Pr \gg 1$
(8-71a)	$Nu_m = 0.664 Pr^{1/3} Re_L^{1/2}$ (average)	Laminar	Flow over a flat plate, constant wall temperature, $Re_L \leq 5 \times 10^5$; $0.6 < Pr < 10$

* Fluid properties are evaluated at the film temperature $T_f = (T_w + T_\infty)/2$ if no viscosity correction is included.

Figura 2.1- Resumo das correlações para convecção forçada sobre corpos 1/3 Fonte: OZISIK (1985)

Table 8-6 (Continued)

Equation number	Correlation	Flow regime	Remarks
(8-71b)	$Nu_m = 0.678 Pr^{1/3} Re_L^{1/2}$ (average)	Laminar	Flow over a flat plate, constant wall temperature, $Re_L \leq 5 \times 10^5$, $Pr \gg 1$
(8-73a)	$St_x Pr^{1/3} = 0.0296 Re_x^{-0.2}$ (local)	Turbulent	Flow over a flat plate for $5 \times 10^5 > Re_x > 10^7$
(8-73b)	$St_x Pr^{2/3} = 0.185(\log Re_x)^{-2.584}$ (local)	Turbulent	Flow over a flat plate for $10^7 < Re_x < 10^9$
(8-74)	$Nu_x = 0.029 Re_x^{0.8} Pr^{0.43}$ (local)	Turbulent	Flow over a flat plate for $Re_x > 2 \times 10^5$ to 5×10^5
(8-78)	$Nu_m = 0.036 Pr^{0.43} \cdot (Re_L^{0.8} - 9200) \left(\frac{\mu_\infty}{\mu_w} \right)^{0.25}$ (average)	Laminar and turbulent	Flow over a flat plate, small free-stream turbulence, for $2 \times 10^5 < Re_L < 5.5 \times 10^6$ $0.70 < Pr < 380$ $0.26 < \frac{\mu_\infty}{\mu_w} < 3.5$
(8-81)	$Nu_m = (0.4 Re^{0.5} + 0.06 Re^{2/3}) \cdot Pr^{0.4} \cdot \left(\frac{\mu_\infty}{\mu_w} \right)^{0.25}$		Flow across a single cylinder, for $40 < Re < 10^5$ $0.67 < Pr < 300$ $0.25 < \frac{\mu_\infty}{\mu_w} < 5.2$
(8-82)	$Nu_m = 0.3 + \frac{0.62 Re^{1/2} Pr^{1/3}}{[1 + (0.4/Pr)^{1/4}]^{1/4}} \cdot \left[1 + \left(\frac{Re}{282,000} \right)^{5/8} \right]^{4/5}$		Flow across a single cylinder, for $10^2 < Re < 10^7$ and $Pe = Re Pr > 0.2$
(8-84)	$Nu_m = (0.8237 - \ln Pe)^{-1}$		Flow across a single cylinder for $Pe < 0.2$
(8-85)	$Nu_m = c \left(\frac{u_\infty D_e}{\nu} \right)^n$ constant c and n are given in Table 8-2		Flow across a single noncircular cylinder

Figura 2.2 Resumo das correlações para convecção forçada sobre corpos 2/3 Fonte: OZISIK (1985)

(8-87)	$Nu_m = 0.37 Re^{0.6}$	Flow of gases across a single sphere for $17 < Re < 70,000$
(8-88)	$Nu_m = 2 + (0.4 Re^{0.5} + 0.06 Re^{2/3}) \cdot Pr^{0.4} \cdot \left(\frac{\mu_\infty}{\mu_w} \right)^{0.25}$	Flow across a single sphere for $3.5 < Re < 8 \times 10^4$ $0.7 < Pr < 380$ $1 < \frac{\mu_\infty}{\mu_w} < 3.2$
(8-95a)	$\frac{h_m D}{k} = 1.13 c_0 Re^n Pr^{1/3}$ where $Re = DG_{max}/\mu$; coefficients c_0 and n given in Table 8-3	Flow across tube bundles having 10 or more transverse rows in direction of flow and for $2000 < Re < 40,000$, $Pr > 0.7$, $N \geq 10$
(8-96)	$h_N = c_1 h_{N \geq 10}$ Correction factor c_1 is given in Table 8-4.	To correct h_m given by Eq. (8-95a) for tube bundles having $1 \leq N < 10$
(8-97)	$\frac{h_m D}{k} = c_2 Re^m Pr^{0.36} \left(\frac{Pr_b}{Pr_s} \right)^n$ $n = \begin{cases} 0 & \text{for gases} \\ \frac{1}{4} & \text{for liquids} \end{cases}$ c_2 and m given in Table 8-5	Flow across tube bundles for $0.7 < Pr < 500$ and $N \geq 20$
(8-98)	$Nu_N = c_3 Nu_{N \geq 20}$ Correction factor c_3 is given in Fig. 8-12.	To correct Nu_m given by Eq. (8-97) for tube bundles having $1 \leq N \leq 20$
(8-99)	$\Delta P = f \frac{NG_{max}^2}{2\rho} Z$ f and Z are given in Figs. 8-13 and 8-14.	Pressure drop for flow across tube bundles
(8-100)	$Nu_m = 4.03 + 0.228 (Re Pr)^{0.67}$	Mercury flow across a staggered, equilateral tube arrangement; $20,000 < Re < 80,000$

Figura 2.3 - Resumo das correlações para convecção forçada sobre corpos 3/3 Fonte: OZISIK (1985)

Esse resumo aborda apenas o capítulo de convecção forçada sobre corpos, e exemplifica toda a energia já depositada pela comunidade científica até hoje para elaboração dessas correlações, além de destacar a quantidade de soluções limitadas apenas a condições restritas, sendo pouco generalistas. Existem ainda as correlações para convecção forçada dentro de tubos, convecção livre, e casos de radiação e condução.

2.2 APRENDIZADO DE MÁQUINA

Para o tema de aprendizado de máquina BRUNTON (2022) traz a explicação de diversos algoritmos aplicados a soluções de engenharia, mais especificamente em sistemas dinâmicos. O livro traz à tona o poder do aprendizado de máquina para soluções com viés científico, fora das aplicações comerciais usualmente vistas. Dentre os algoritmos abordados destacam-se para esse estudo aqueles que têm como proposta devolver uma expressão analítica como produto, tais como programação genética, que será abordado posteriormente, e SINDy por exemplo.


Já o artigo de KWON (2020) traz a aplicação de aprendizado de máquina para um sistema de transferência de calor convectiva. O trabalho analisa a transferência de calor para um escoamento interno em um duto, variando a capilaridade do canal. Kwon valida seu modelo de aprendizado de máquina com simulações CFD. Esse artigo demonstra a aplicabilidade do aprendizado de máquina à problemas termodinâmicos.

3 CONVECÇÃO DE CALOR FORÇADA AO REDOR DO CILINDRO


A convecção forçada é um modo de transporte de energia na forma de calor envolvendo fluidos em movimento. Esse mecanismo é utilizado em aplicações de engenharia, tal como os trocadores de calor. O cálculo da transferência de calor nessas condições é de suma importância para dimensionamento de tais projetos.

Um problema clássico de convecção forçada é o de escoamento do fluido ao redor de um cilindro. Com a variação das condições de contorno do problema, o cálculo da transferência de calor pode se tornar mais complexo. O acréscimo do número de Reynolds por exemplo, pode alterar a forma do escoamento atrás do cilindro, como visto na figura 3.1 do estudo Lienhard (1966), afetando o transporte de calor pelo fluido, apresentado na figura 3.2, com dados do estudo de Giedt's (1949).


Visto a complexidade do problema, o presente trabalho propõe o uso de métodos de aprendizado de máquina para cálculo da transferência de calor em sistemas desse tipo.



$Re_D < 5$ Regime of unseparated flow.



$5 \text{ to } 15 \leq Re_D < 40$ A fixed pair of Föhl vortices in the wake




$40 \leq Re_D < 90$ and $90 \leq Re_D < 150$

Two regimes in which vortex street is laminar:


Periodicity governed in low Re_D range by wake instability

Periodicity governed in high Re_D range by vortex shedding.




$150 \leq Re_D < 300$ Transition range to turbulence in vortex.

$300 \leq Re_D \lesssim 3 \times 10^5$ Vortex street is fully turbulent, and the flow field is increasingly 3-dimensional.



$3 \times 10^5 \lesssim Re_D < 3.5 \times 10^6$

Laminar boundary layer has undergone turbulent transition. The wake is narrower and disorganized. No vortex street is apparent.



$3.5 \times 10^6 \leq Re_D < \infty (?)$

Re-establishment of the turbulent vortex street that was evident in $300 \leq Re_D \lesssim 3 \times 10^5$. This time the boundary layer is turbulent and the wake is thinner.

Figura 3.1 Regimes de escoamento através de um cilindro Fonte: Lienhard (1966)




Figura 3.2 Medidas de Geidt's de transferência de calor local em um escoamento de ar ao redor de cilindro. Fonte: Geidt's (1949).

Churchill e Bernstein (1977) abordam em sua pesquisa as diferentes razões para a falta de sucesso anteriormente nesse campo, como diferentes teorias para regimes de baixo número de Reynolds, a influência da convecção natural nesse tipo de regime, entre outros.

No entanto, os autores conseguem desenvolver em seu estudo uma equação única para a taxa de transferência de massa e calor, para cilindro em um escoamento transversal. A equação, Eq. (3.1), cobre a variação dos números de Prandtl e de Reynolds.

$$Nu = 0.3 + \frac{0.62 Re^{\frac{1}{2}} Pr^{\frac{1}{3}}}{\left[1 + (0.4/Pr)^{\frac{2}{3}}\right]^{\frac{1}{4}}} \left[1 + \left(\frac{Re}{282000}\right)^{\frac{5}{8}}\right]^{\frac{4}{5}} \quad (3.1)$$

Onde :

Nu: Número de Nusselt

Re: Número de Reynolds

Pr: Número de Prandtl

Para $Re < 4000$ o termo $\left[1 + \left(\frac{Re}{282000}\right)^{\frac{5}{8}}\right]^{\frac{4}{5}}$ é $\cong 1$, então:

$$Nu = 0.3 + \frac{0.62 Re^{\frac{1}{2}} Pr^{\frac{1}{3}}}{\left[1 + (0.4/Pr)^{\frac{2}{3}}\right]^{\frac{1}{4}}} \quad (3.2)$$

No intervalo $40000 < Re < 400000$ resultados da Eq. (2.1) se encontram abaixo dos dados experimentais em cerca de 20%. Nesse caso, erros menores são dados por:

$$Nu = 0.3 + \frac{0.62 Re^{\frac{1}{2}} Pr^{\frac{1}{3}}}{\left[1 + (0.4/Pr)^{\frac{2}{3}}\right]^{\frac{1}{4}}} \left[1 + \left(\frac{Re}{282000}\right)^{\frac{1}{2}}\right] \quad (3.3)$$

No estudo, a correlação foi comparada com outros casos experimentais para validação, como pode ser visto na Figura 3.3.




Figura 3.3 - Comparação da correlação de Churchill e Bernstein com dados experimentais de outros trabalhos Fonte: Adaptado de LIENHARD (2005)

4 APRENDIZADO DE MÁQUINA

4.1 ALGORITMO GENÉTICO

Algoritmo genético é um algoritmo baseado em princípios de otimização de seleção natural e aptidão. Uma população inicial de x sistemas é definida, cada sistema com um estado inicial aleatório. A função custo é aplicada para cada sistema, e o valor calculado define a aptidão do sistema, quanto menor o valor da função mais apto o sistema é considerado e vice-versa. Sistemas mais aptos são selecionados para moldar a população, enquanto sistemas menos aptos tendem a ser substituídos. Na sequência uma nova população é gerada, formado pelos sistemas mais aptos, e a nova população repete o processo. O processo pode ser visualizado no diagrama da Figura 4.1



Figura 4.1 - Diagrama ilustrando a lógica do algoritmo genético. Fonte: <https://icaroagostino.github.io/post/sbo/>

Cada população representa uma geração, e o processo de seleção pode ser repetido n vezes por n gerações. O objetivo é que, assim como na seleção natural, os sistemas mais aptos

tenham sido mais selecionados e mantenha suas características na população, de forma que as gerações evoluam para um sistema de menor custo.

Entre duas gerações consecutivas, os sistemas são selecionados e alterados, representando uma evolução a próxima geração. Algumas das operações que podem ocorrer com os sistemas são; elitismo, onde o sistema é copiado inteiramente para a próxima geração; replicação, que tem o mesmo efeito do elitismo, porém acontece de forma aleatória entre a população, enquanto o elitismo é garantido para os melhores sistemas; crossover, onde dois sistemas trocam parte da sua sequência um com o outro; mutação que altera um valor da sequência aleatoriamente, visando explorar novos resultados.

Essa dinâmica é ilustrada no livro de BRUNTON (2022), no esquemático da figura 4.2




Figura 4.2 Esquema ilustrando um algoritmo genético Fonte: Traduzido de BRUNTON (2022)

4.2 PROGRAMAÇÃO GENÉTICA

Programação genética é uma poderosa generalização de algoritmos genéticos que otimiza simultaneamente a estrutura e os parâmetros de um sistema de input/output. Através da programação genética é possível treinar um modelo de aprendizado de máquina de regressão simbólica, ou seja, que tem como produto resultante uma equação. Para visualização podemos imaginar uma função como uma árvore de função, onde cada folha é uma variável ou constante,

os nós são operações matemáticas, e a raiz é o resultado da função. A função $a = b_1^2 + 1$, por exemplo, pode ser representada pela árvore da Figura 4.3




Figura 4.3 Função representada como árvore de função

Na programação genética, a população é constituída por árvores de funções, e são as estruturas dessas árvores que sofrem as alterações de replicação, crossover e mutação. O programador pode ajustar a porcentagem de chance de cada uma dessas operações na árvore, para que o modelo se adeque melhor ao problema, conforme ilustrado na Figura 4.4.




Figura 4.4 Operações usadas nas árvores de funções, e as taxas para cada operação Fonte: Traduzido de BRUNTON (2022)

O modelo de regressão simbólica utilizado no desenvolvimento desse trabalho tem como base a programação genética.

4.3 BASE DE DADOS

O primeiro passo para o desenvolvimento do modelo foi a coleta de dado. Os dados escolhidos foram os de alguns dos experimentos, citados no trabalho de Churchill e Bernstein(1977), mais especificamente os de Hilpert(1933), Schimdt e Wenner(1941) e Fand e Keswani(1972). Esses estudos contêm dados experimentais para convecção forçada ao redor do cilindro, e serão usados para o treinamento do modelo de aprendizado de máquina. Schimdt e Wenner(1941) e Hilpert(1933) trabalham com ar como fluido no escoamento, enquanto Fand

e Keswani(1972) utilizaram água. Com isso temos uma base de dados de 234 experimentos, com diferentes números de Reynolds e Prandtl.




Figura 4.5 – Distribuição dos dados usados no desenvolvimento do modelo.

Observando os histogramas da figura 4.5 é evidente que os dados usados estão concentrados majoritariamente em números de Reynolds mais baixos. Essa distribuição é decorrente principalmente da dificuldade de se realizar experimentos com precisão em número de Reynolds mais elevados. Esse desequilíbrio pode ter consequências nos resultados encontrados pelo modelo de aprendizado de máquina, e será discutido na conclusão. A base de dados completa utilizada pode ser encontrada no apêndice A.1

Para auxiliar na visualização para os dados com $Re > 50000$, segue a figura 4.6:




Figura 4.6 – Distribuição dos dados utilizados no desenvolvimento do modelo para $Re > 50000$

Uma alternativa válida para contornar essa situação seria, no lugar de usar dados experimentais, gerar uma base de dados a partir de simulações feitas em CFD. Dessa forma, poderia ser controlado o equilíbrio da distribuição dos dados de entrada, além de maior diversidade dos dados. Essa alternativa, porém, foi descartada devido ao custo computacional e de tempo necessários para rodada das simulações.

4.4 DESENVOLVIMENTO DO MODELO

Para o desenvolvimento do modelo a linguagem de programação escolhida foi o Python. O Python é uma linguagem amplamente utilizada para implementações de aprendizado de máquina, contando com diversos recursos e bibliotecas já desenvolvidos, que facilitam e aceleram a implementação dos algoritmos.

Para o modelo foi escolhido o algoritmo de regressão simbólica da biblioteca GP Learn (<https://gplearn.readthedocs.io>), que faz uso de programação genética em seu funcionamento. Do ponto de vista científico a regressão simbólica é interessante por ter como dado de saída uma equação analítica. Com isso, é possível comparar a equação encontrada com outras expressões de correlação presentes na literatura para o dado problema, e possivelmente comparar onde a máquina aprendeu relações que não foram exploradas anteriormente. Existem outros algoritmos que muitas vezes são mais robustos e precisos, porém após o treinamento, o resultado é fornecido em termos de uma caixa preta, não nos permitindo avaliar quais decisões

a máquina tomou para chegar aqueles resultados, além de não ser prático de se compartilhar com outros pesquisadores.

A base de dados será dividida aleatoriamente em duas, uma base de treinamento e uma de validação. A base de validação tem como função avaliar métricas do modelo após o treinamento, sendo possível julgar como se comporta com dados ainda não vistos pelo modelo, e observar eventuais underfit e overfit.

Definidos o algoritmo e a base de dados, é possível treinar o modelo. Certos parâmetros do modelo podem ser alterados, e diferentes parametrizações serão testadas até encontrar o modelo mais adequado ao problema. Os principais parâmetros que podem ser alterados são:

- Tamanho da população
- Número de gerações
- Função de custo
- Operadores matemáticos
- Proporção da base de treinamento

Após o treinamento o modelo é possível avaliar seu desempenho. É possível analisar a convergência do modelo aos dados através do coeficiente de determinação (R^2). Usando os valores da função de custo é possível avaliar como está ocorrendo a evolução ao longo das gerações. Além disso também é feita uma análise qualitativa dos valores previstos e dos valores alvos, para tentar encontrar algum viés para a imprecisão do modelo. Após avaliação, os parâmetros são adequados, e então é treinado um novo modelo. O processo se repete até que se encontre os parâmetros que melhor se ajustem ao problema.

4.5 COEFICIENTE DE DETERMINAÇÃO (R^2)

O coeficiente de determinação mede o quanto a equação encontrada se adequa aos dados, e seu valor é dado por:

$$R^2 = 1 - \frac{SQ_{res}}{SQ_{tot}} \quad (4.1)$$

Onde,

R^2 : *coeficiente de determinação*

SQ_{res} : *Soma do quadrado dos resíduos*

SQ_{tot} : *Soma total dos quadrados*

$$Q_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4.2)$$

Onde,

y_i : *valor observado*

$\hat{y}_i$: *valor previsto para y_i*

$$SQ_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (4.3)$$

Onde,

$\bar{y}$: *média das observações*

Dessa forma, R^2 varia entre 0 e 1, onde 1 representa uma regressão perfeitamente alinhada com os dados, e 0 uma regressão que não representa a tendência dos dados observados de nenhuma forma.




Figura 4.7 – Exemplos de valores de comportamento de R^2 Fonte: Glen (2022)

5 RESULTADOS

5.1 MODELO 1

O primeiro modelo possui os seguintes parâmetros e resultados:

Tabela 5.1- Parâmetros e resultados do modelo 1

Parâmetros	
Tamanho da população	4000
Número de gerações	21
Função de custo	MAE
Operadores Matemáticos	+, -, x, /, √, ^-1
Proporção da base de treinamento	85%
Resultados	
Coeficiente de determinação(R^2)	93.94%
Função de custo - Treinamento	4.38
Função de custo - Validação	15.62




Figura 5.1- Evolução da função de custo do modelo 1




Figura 5.2- Comparação dos dados experimentais, previstos pelo modelo1, e calculados da equação de Churchill-Bernstein

Após oscilar nas primeiras gerações, o erro da base de validação estabiliza, e a diferença entre os custos demonstra que o modelo não está sendo capaz de generalizar a solução para fora do treinamento. Além disso o R^2 de 93% não é satisfatório.




Figura 5.3 - Valores dos erros do modelo 1 e da equação de Churchill-Bernstein

5.2 MODELO 2

Para o modelo 2 foi alterada a função de custo de MAE para MSE. A intenção é que o modelo seja mais punitivo com o erro, buscando melhor convergência. Os resultados do modelo 2 foram:

Tabela 5.2- Parâmetros e resultados do modelo 2

Parâmetros	
Tamanho da população	4000
Número de gerações	21
Função de custo	MSE
Operadores Matemáticos	+, -, x, /, √, ^-1
Proporções de operações genéticas	Padrão GP Learn
Proporção da base de treinamento	85%
Resultados	
Coeficiente de determinação(R^2)	96%
Função de custo - Treinamento	72.21
Função de custo - Validação	733.96




Figura 5.4- Evolução da função de custo do modelo 2




Figura 5.5 - Comparação dos dados experimentais, previstos pelo modelo2, e calculados da equação de Churchill-Bernstein




Figura 5.6 - Valores dos erros do modelo 2 e da equação de Churchill-Bernstein

O modelo apresentou uma evolução no R^2 para 96%, consequência positiva da mudança da função de custo. No entanto, a evolução do modelo ainda estabiliza para a base validação, após a sétima geração. Além disso, é possível observar na figura 4.4 que o modelo tem a tendência de continuar se afastando do valor alvo com o aumento do número de Reynolds. Esses dados mostram que o modelo não está sendo capaz de criar as regras de generalização adequadas para os dados de treino.

5.3 MODELO 3

Para o próximo modelo, foi usado o conhecimento do problema, e adicionado ao conjunto de operações matemáticas, expressões vistas na Eq 3.1, com isso aumentamos o leque de ferramentas para o algoritmo utilizar. O modelo 3 teve os seguintes resultados:

Tabela 5.3- Parâmetros e resultados do modelo 3

Parâmetros	
Tamanho da população	4000
Número de gerações	21
Função de custo	MAE
Operadores Matemáticos	$+$, $-$, $\times$, $/$, $\sqrt{}$, $\wedge^{-1}$, $\wedge^{(4/5)}$, $\wedge^{(5/8)}$, $\wedge^{(1/3)}$, $\wedge^{(1/4)}$, $\wedge^{(2/3)}$
Proporção da base de treinamento	85%
Resultados	
Coeficiente de determinação(R^2)	99.53%
Função de custo - Treinamento	27.75
Função de custo - Validação	21.05




Figura 5.7-Evolução da função de custo do modelo 3




Figura 5.8- Comparação dos dados experimentais, previstos pelo modelo3, e calculados da equação de Churchill-Bernstein




Figura 5.9 - Valores dos erros do modelo 3 e da equação de Churchill-Bernstein

O modelo 3 apresenta uma generalização satisfatória, com R^2 de acima de 99%, e é possível observar que também está sendo capaz de generalizar para novos casos, visto a evolução dos valores da função de custo para os dados de validação.

No entanto, ao longo de tantas gerações a árvore função de saída do modelo se tornou excessivamente complexa (Figura 5.10). Com esse resultado a escolha de usar a regressão simbólica perde força, já que a vantagem de conhecermos a função não nos traz nenhuma análise mais profunda, visto sua complexidade.




Figura 5.11- Evolução da função de custo do modelo 4




Figura 5.12- Comparação dos dados experimentais, previstos pelo modelo4, e calculados da equação de Churchill-Bernstein




Figura 5.13 - Valores dos erros do modelo 4 e da equação de Churchill-Bernstein

Apesar do valor de R^2 diminuir e da função custo aumentarem, a árvore função se tornou mais simples (figura 4.10), e podemos definir a função encontrada de forma que seja compreensível para futuras análises.




Figura 5.14- Árvore função do modelo 4

Podemos escrever a função da Figura 5.14 como:

$$Nu = \left(0.093766 Pr^{\frac{5}{8}} Re - Pr^{\frac{5}{8}} + (Pr - Re)^{\frac{5}{8}} \right)^{\frac{5}{8}} \quad (5.1)$$

6 CONCLUSÕES

O modelo 4 contempla um bom resultado de modo geral para o estudo. O modelo aprendeu a partir dos dados cedidos, e conseguiu métricas semelhantes para dados fora da base de treinamento. Além disso, o coeficiente de determinação acima de 98% demonstra que conseguiu uma boa correlação com os dados experimentais da base. Por fim, alcançou o objetivo de gerar uma equação analítica representando a correlação dos dados percebida pelo modelo.

A correlação encontrada (Eq. 5.1) possui erros inferiores a correlação de Churchill-Bernstein (Eq. 3.1) nos dados testados. Isso aponta que o aprendizado de máquina pode se tornar uma ferramenta poderosa para se encontrar novas correlações nesse campo de estudo, podendo ser testado para casos mais complexos.

Os resultados, no entanto, apresentam erros maiores para números de Reynolds elevados. Como visto no capítulo 4.3, a densidade de dados para essa região é consideravelmente menor, o que impacta o aprendizado nesse intervalo.

6.1 SUGESTÕES PARA TRABALHOS

A partir do estudo realizado, pode-se apresentar sugestões e recomendações para trabalhos futuros:

- Fazer uso de ferramentas em CFD para geração de uma nova base de dados, que possua maior quantidade, variedade e equilíbrio de dados
- Treinamento do modelo em diferentes intervalos de números de Reynolds, para tentar contornar o desequilíbrio dos dados
- Testar o algoritmo para outras correlações no campo de transferência de calor e massa.

7 REFERÊNCIAS BIBLIOGRÁFICAS

BADILLO, Solveig et al. An introduction to machine learning. **Clinical pharmacology & therapeutics**, v. 107, n. 4, p. 871-885, 2020.

BRUNTON, Steven L.; KUTZ, J. Nathan. **Data-driven science and engineering: Machine learning, dynamical systems, and control**. Cambridge University Press, 2022.

CHURCHILL, S. W.; BERNSTEIN, M. A correlating equation for forced convection from gases and liquids to a circular cylinder in crossflow. *J. Heat Transfer*, 99:300-306, 1977.

FAND, R. M.; KESWANI, K. K. The influence of property variation on forced convection heat transfer to liquids. **International Journal of Heat and Mass Transfer**, v. 15, n. 8, p. 1515-1536, 1972.

GIEDT, W. H. Investigation of variation of point unit heat transfer coefficient around a cylinder normal to an air stream. **Trans. ASME**, v. 71, p. 375-381, 1949.

Glen, Stephannie. R-Squared in One Picture. Data Science Central, 2019. Disponível em: <<https://www.datasciencecentral.com/r-squared-in-one-picture/>>. Acesso em: 20 nov. 2022

GÉRON, Aurélien. **Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow**. "O'Reilly Media, Inc.", 2022.

HILPERT, R. Wärmeabgabe von geheizten Drähten und Rohren im Luftstrom. **Forschung auf dem Gebiet des Ingenieurwesens A**, v. 4, n. 5, p. 215-224, 1933.

KWON, Beomjin; EJAZ, Faizan; HWANG, Leslie K. Machine learning for heat transfer correlations. **International Communications in Heat and Mass Transfer**, v. 116, p. 104694, 2020.

LIENHARD, I. V.; JOHN, H. **A heat transfer textbook**. phlogiston press, 2005.

LIENHARD, John H. et al. **Synopsis of lift, drag, and vortex frequency data for rigid circular cylinders**. Pullman, WA: Technical Extension Service, Washington State University, 1966.

OZISIK, M. Necati. **Heat transfer: a basic approach**. New York: McGraw-Hill, 1985.

SAMUEL, Arthur L. Some studies in machine learning using the game of checkers. II—Recent progress. **IBM Journal of research and development**, v. 11, n. 6, p. 601-617, 1967.

SCHMIDT, Ernst; WENNER, Karl. Wärmeabgabe über den Umfang eines angeblasenen geheizten Zylinders. **Forschung auf dem Gebiet des Ingenieurwesens A**, v. 12, n. 2, p. 65-73, 1941

APÊNDICE A. DADOS

A.1 DADOS EXPERIMENTAIS

Tabela A 1 – Dados experimentais Fonte: SCHMIDT (1941); HILPERT (1933); FAND (1972)

Re	Nu	Pr
500	21.9	6.76
600	30.6	6.94
600	30.6	6.33
700	33.1	7.08
700	33	6.49
700	32.7	5.98
800	35.3	7.19
800	35.2	6.62
800	34.1	6.12
800	34.4	5.67
900	36.9	7.21
900	37.1	6.73
900	36.7	6.24
900	36.3	5.8
900	35.3	5.03
1000	38.6	1.34
1000	38.9	6.82
1000	38.5	6.34
1000	38.2	5.92
1000	31.2	5.17
1100	40.3	7.41
1100	40.4	6.89
1100	40	6.42
1100	39.8	6.01
1100	38.8	5.28
1100	37.8	4.62
1200	42.1	7.47
1200	41.9	6.96
1200	41.5	6.5
1200	41.3	6.09
1200	40.4	5.31
1200	39.5	4.13
1300	43.6	7.52
1300	43.4	7.02
1300	43.1	6.58
1300	42.6	6.17
1300	41.9	5.46
1300	41	4.83

Continuação da Tabela A.1

Re	Nu	Pr
1400	45	7.57
1400	45	7.09
1400	44.6	6.65
1400	44.2	6.25
1400	43.2	5.54
1400	42.4	4.92
1400	41	4.24
1500	45	7.51
1500	46.6	7.15
1500	46.3	6.72
1500	45.7	6.32
1500	44.6	5.61
1500	43.9	5
1500	42.6	4.34
1600	48.2	6.8
1600	47.1	6.38
1600	46	5.69
1600	45.1	5.07
1600	44.1	4.43
1600	43	3.92
1700	48.5	6.44
1700	47.4	5.76
1700	46.4	5.15
1700	45.4	4.51
1700	44.5	4
1800	48.8	5.83
1800	47.1	5.21
1800	46.6	4.58
1800	45.8	4.08
1800	45	3.65
1900	48.9	5.28
1900	47.1	4.64
1900	47	4.14
1900	46.3	3.73
2000	50.1	5.34
2000	48.7	4.69
2000	48.1	4.2
2000	47.6	3.79
2100	49.1	4.14
2100	49.1	4.26
2100	48.7	3.85
2100	47.9	3.49
2200	50.6	4.79

Continuação da Tabela A.1

Re	Nu	Pr
2200	50	4.3
2200	49.7	3.9
2200	49	3.54
2300	50.8	4.34
2300	50.5	3.94
2300	50	3.59
2400	51.6	4.38
2400	51.3	3.98
2400	50.9	3.63
2500	51.9	4.01
2500	51.6	3.67
2600	52.3	3.71
2700	53	3.74
21200	94	0.7
33920	126	0.7
52800	173	0.7
8290	51.4	0.7
170000	384	0.7
39800	141	0.7
64450	196	0.7
15550	76	0.7
101300	264	0.7
39200	118	0.7
102000	233	0.7
257600	472	0.7
426000	711	0.7
2.11	1.14	0.7
2.85	1.27	0.7
3.41	1.33	0.7
4.39	1.47	0.7
5.25	1.54	0.7
6.15	1.65	0.7
8.84	1.92	0.7
10.7	2.03	0.7
13.79	2.21	0.7
17.46	2.44	0.7
22.76	2.72	0.7
3.63	1.35	0.7
4.22	1.43	0.7
4.84	1.5	0.7
5.72	1.59	0.7
6.37	1.69	0.7
7.47	1.76	0.7

Continuação da Tabela A.1

Re	Nu	Pr
7.01	1.73	0.7
9.47	1.95	0.7
13.49	2.22	0.7
14.98	2.29	0.7
18.69	2.53	0.7
21.89	2.68	0.7
28.7	2.96	0.7
35.56	3.27	0.7
41.38	3.48	0.7
48.3	3.73	0.7
56.9	4	0.7
66.75	4.34	0.7
16.82	2.42	0.7
21.29	2.65	0.7
24.7	2.81	0.7
30.08	3.08	0.7
39.65	3.44	0.7
49.25	3.78	0.7
57.5	4.07	0.7
66.1	4.34	0.7
76.8	4.64	0.7
96.5	5.24	0.7
120.8	5.98	0.7
150.8	6.37	0.7
34.13	3.2	0.7
43.05	3.53	0.7
48.7	3.75	0.7
59.5	4.1	0.7
69.4	4.43	0.7
68.2	4.29	0.7
82.4	4.74	0.7
105.8	5.35	0.7
120.2	5.71	0.7
133.2	6.02	0.7
136	6.13	0.7
159.2	6.51	0.7
169.8	6.82	0.7
209.3	7.51	0.7
301.5	8.94	0.7
351	9.54	0.7
421.5	10.43	0.7
519	11.36	0.7
636	12.3	0.7

Continuação da Tabela A.1

Re	Nu	Pr
739	13.55	0.7
189.9	7.06	0.7
251.5	8.1	0.7
270.2	8.5	0.7
301.2	8.84	0.7
373.5	9.83	0.7
449	10.68	0.7
490	11.02	0.7
581	11.88	0.7
644	12.29	0.7
689	12.81	0.7
909	14.3	0.7
1074	15.57	0.7
1331	17.28	0.7
1552	18.48	0.7
508	11.48	0.7
616	12.43	0.7
761	13.7	0.7
906	14.82	0.7
1253	17.36	0.7
1688	19.79	0.7
1822	20.7	0.7
2098	21.93	0.7
2522	24.1	0.7
3125	26.9	0.7
3755	29.18	0.7
2410	22.50	0.7
3210	26.06	0.7
4230	29.65	0.7
5260	34.05	0.7
6480	38.75	0.7
7800	44.5	0.7
10870	53.8	0.7
14110	64.1	0.7
17580	74.1	0.7
24390	90.8	0.7
28980	103.4	0.7
36510	117.9	0.7
6040	37.8	0.7
6890	41.7	0.7
8800	48	0.7
13350	61.6	0.7
17650	72.6	0.7

Continuação da Tabela A.1

Re	Nu	Pr
25000	89.5	0.7
32300	106.8	0.7
41900	128.7	0.7
49600	144.7	0.7
55750	158.5	0.7
14790	63.9	0.7
20780	78.6	0.7
27820	94.8	0.7
40320	119.6	0.7
51600	143.5	0.7
62950	170.5	0.7
85400	215.3	0.7
105200	252.8	0.7
132300	310	0.7
30900	106	0.7
40760	130.7	0.7
41600	130.5	0.7
75700	197.4	0.7
104200	261.3	0.7
118000	279	0.7
133200	316	0.7
150300	348	0.7
164400	369	0.7
174000	401	0.7
200000	449	0.7
231000	513	0.7